

Evaluation of the Performance of Neural Network-Based Surrogate Models Applied to Multi-Objective Optimization Problems in Bioinformatics

António Araújo PG59752

Orientadores:

António Cunha, Ana Maria A. C. Rocha

Contextualização

1- Complexidade real:

A maioria dos problemas reais exige a otimização de múltiplos objetivos conflitantes, gerando uma frente de Pareto.



2 - Gargalo Computacional:

Avaliar cada solução através de simulações físicas ou algoritmos numéricos é computacionalmente dispendioso para a repetição exigida por MOEAs.



3 - Modelos de substituição:

Os modelos de substituição (surrogates) de Machine Learning permitem limitar o uso computacional na busca por soluções ótimas, ou aproximações das mesmas.




Caso de Estudo

Organismo: *Escherichia coli*

Composto: Triptofano

Objetivos conflitantes:

- Maximizar biomassa
- Maximizar fluxo de produto
- Minimizar o n° de knockouts
- Minimizar o consumo de glucose



Objetivos

- i. Formular a otimização da produção de triptofano em *Escherichia coli* como um problema de otimização multiobjetivo.
- ii. Identificar os modelos substitutos (surrogates) mais adequados para este tipo de problema.
- iii. Implementar e adaptar estes modelos substitutos ao problema em estudo.
- iv. Integrar os modelos substitutos com algoritmos evolutivos multiobjetivo (MOEAs).
- v. Comparar o desempenho dos diferentes modelos substitutos, particularmente nas regiões próximas da fronteira de Pareto.

Metodologia

Dataset

- Modelo iML1515 (E. coli, 1516 genes)
- 5000 simulações FBA aleatórias
- Para cada simulação:
 - Glucose e O2 aleatórios [0.1, 20]
 - 1 a 6 genes em knockout
 - FBA – maximizar biomassa
 - FBA – maximizar triptofano
- Resultado: dataset com 4916 amostras válidas

Metodologia (cont.)

Arquitetura da rede neuronal

1- Embeddings

ANN

Inputs:

- Glucose
- O2
- NK
- g1, g2, g3, g4, g5, g6

Outputs:

- Product flux
- Biomass

2- Multi Hot encoding

ANN

Inputs:

- Glucose
- O2
- NK
- b0002, b0003, ..., s0001

Outputs:

- Product flux
- Biomass

3- Classificadores

Modelo 1: SVM (Viability)

Inputs:

- Glucose
- O2
- Knockouts

Output:

- Biomass (0/1)

Modelo 2: SVM (Product positive)

Inputs:

- Glucose
- O2
- Knockouts

Output:

- Product flux (0/1)

Modelo 3: ANN

Treinada apenas com casos:


- biomass > 0
- Product flux > 0

Outputs:

- Biomass
- Product flux


Resultados

Dataset




Resultados (cont.)

1- Embeddings



MAE - 0.103441

R² - 0.4946




MAE - 0.765319


R² - 0.5081

Resultados (cont.)

2 - Multi hot encoding



MAE - 0.070977161
 R^2 - 0.822478227



MAE - 0.541077735
 R^2 - 0.824731085

Discussão

Análise do Dataset (Glucose vs Biomassa):

- A biomassa aumenta com a glucose mas com grande variabilidade
- O mesmo nível de glucose pode originar biomassas muito diferentes consoante os genes em knockout
- Zeros não dependem da glucose, resultam de combinações letais de genes
- Esta variabilidade intrínseca do dataset limita a capacidade de aprendizagem de qualquer modelo

Embeddings:

- Previsões precisas para valores $\neq 0$ – pontos próximos da diagonal
- Não aprende os zeros – coluna vertical dispersa em $x=0$

Multi-hot Encoding:

- Melhor aprendizagem dos zeros face aos Embeddings
- R^2 global superior (0.82 vs 0.49)
- Maior dispersão nos valores $\neq 0$ comparado com Embeddings

Critério	Embeddings	Multi-hot encoding
R ² Biomass	0.49	0.82 (+67%)
R ² Product	0.51	0.82 (+61%)
MAE Biomass	0.103	0.071 (-31%)
MAE Product	0.765	0.541 (-29%)
Previsão zeros	Não aprende	Aprende parcialmente
Precisão $\neq 0$	Muito próximo diagonal	Maior dispersão



Trabalhos em curso e futuro trabalho

- Treinar a abordagem 3 de arquitetura de redes neuronais
- Integração de MOEAs para otimização real
- Validar resultados do MOEA com FBA
- Comparação de resultados com outros surrogates



Conclusão